

Zastosowanie modeli regresji do przewidywania rozkładów zwycięstw drużyn

Grzegorz Ruchała, Bartłomiej Węgrzyn

Celem pracy będzie przedstawienie procesu budowy różnych modeli regresji przy użyciu języka R.

W pracy wykorzystamy modele regresji liniowej, regresji wielorakiej oraz regresji Poissona.

Bazując na udostępnianych przez ligę NBA danych statystycznych z wcześniejszych sezonów, wykorzystamy te modele do próby oszacowania liczby zwycięstw poszczególnych zespołów ligi w kolejnych sezonach.

Zastosujemy biblioteki leaps oraz MASS oraz narzędzia, które umożliwią automatyzację wyboru zmiennych.

Dodatkowo, zbudujemy modele regresji Poissona, również z wykorzystaniem powyższych bibliotek.

Pokażemy też jak za pomocą metod statystycznych ustalić, który ze zbudowanych modeli osiąga największą dokładność.

Przygotowanie danych

Zacniemy od przygotowania danych oraz podziału na zbiory treningowe i testowe. Zbiorem treningowym będą połączone dane z sezonów 15/16, 16/17, 17/18, a zbiorem testowym dane z sezonu 18/19. Dokonujemy eliminacji kolumn, które nie będą dla nas istotne przy tworzeniu modeli, ze względu na formę (nazwa drużyny, nazwa stadionu) lub powtarzalność (usuwanie liczbę przegranych meczy, gdyż używamy liczby wygranych spotkań).

Usuujemy też wartości odstające, znajdujące się poza kwantylami 0,02 a 0,98 – są to dwie wartości dolne oraz jedna górna, która mogłaby istotnie zaburzyć otrzymane wyniki, ze względu na rekordowy w skali całej historii koszykówki, bilans 73-9 osiągnięty przez GSW w 2015/16.

Utworzenie modeli

W pierwszej kolejności utworzymy model regresji liniowej. Polega ona na dopasowaniu liniowym zależności między zmienną objaśnianą a objaśniającą, przyjmując postać funkcji liniowej $y = \beta_0 + \beta_1 x$.

W modelu tym za zmienną objaśniającą wybieramy MOV (margin of victory), która mówi nam o średniej różnicy zdobywanych punktów w poszczególnych grach – im większa wartość, tym mniej wyrównana gra, a większa różnica w wyniku końcowym.

W modelu regresji wielorakiej wykorzystamy wszystkie 21 zmiennych, które pozostały po początkowych operacjach. Przykładowymi, ciekawymi zmiennymi są: średni wiek zawodników, liczba posiadaczy w ciągu meczu (tempo), rzuty osobiste oraz rzuty za 3 punkty jako procent wszystkich rzutów, zdobyte (ORTg) oraz stracone (DRTg) punkty na 100 posiadaczy.

Utworzenie modeli z wykorzystaniem bibliotek

Przejdziemy teraz do budowy modeli regresji wielorakiej z wykorzystaniem pakietów języka R. W pierwszej kolejności wykorzystamy bibliotekę MASS. Operuje ona na wszystkich zmiennych, które w zautomatyzowanym procesie są odejmowane lub dodawane do modelu, dążąc do minimalizacji kryterium informacyjnego Akaikiego (AIC).

Funkcja stepAIC ma na celu uproszczenie modelu bez znacznego spadku dokładności modelu. Ostatecznie otrzymamy model składający się tylko z 3 zmiennych: MOV, średniego wieku zawodników oraz SRS – statystykę określającą różnicę punktów, uwzględniając siłę rywala.

Drugi z budowanych modeli wykorzystuje bibliotekę leaps. Funkcja pochodząca z tej biblioteki szuka najlepszych zmiennych w oparciu o zadaną metrykę. Dla nas będzie to dopasowane R^2 . Finalnie otrzymamy model zależy od sześciu zmiennych: średniego wieku zawodników, zwycięstw prognozowanych (statystyka bazująca na zdobytych i straconych punktach), SOS – opisującą jak trudnych rywali będzie miał zespół (jest to szczególny przypadek dla tej ligi, gdzie nie z każdym przeciwnikiem rozgrywana jest taka sama liczba gier), procentem rzutów za 3 punkty, procentem celnych rzutów (mając na uwadze różne wartości punktowe za rzut) oraz co ciekawe, średnią liczbę widzów na mecz.

Tabela 1 – Wartości charakterystyk liczbowych dla modeli

	R^2	Dopasowane R^2	AIC	RMSE	MAPE
Regresja liniowa	0.917	0.916	437.65	3.10	6.87%
Regresja wieloraka	0.931	0.907	462.11	3.25	6.43%
Model z MASS	0.923	0.920	435.22	3.02	6.76%
Model z leaps	0.926	0.921	437.28	3.01	6.42%

Regresja Poissona

Rozkład Poissona określa prawdopodobieństwo występowania zdarzeń w danym przedziale czasu, gdy znamy oczekiwaną liczbę zdarzeń, a same zdarzenia są od siebie niezależne.

Zwycięstwa poszczególnych drużyn możemy, przy pewnych założeniach, traktować jako ciąg zdarzeń niezależnych, których częstość jest uzależniona od pewnych czynników, a wynik końcowy może być tylko nieujemną liczbą całkowitą, którą możemy bezpośrednio interpretować:

0 – w przypadku przegranej,

1 – w przypadku wygranej.

Widzimy więc, że zmienna wynikowa, pochodzi z rozkładu Poissona:

$$P(Y = y_i | X_i) = \frac{\exp(-\lambda) \lambda^{y_i}}{y_i!}$$
$$\ln(\lambda_i) = X_i \beta$$
$$\mathbb{E}[X] = \lambda$$

Utworzymy teraz dwa modele w oparciu o regresję Poissona.


Pierwszy z nich, podobnie jak model regresji wielorakiej z użyciem biblioteki MASS, będzie

opierał się na zmiennych: Age, MOV, SRS.

Drugi powstanie z wykorzystaniem funkcji stepAIC. Będzie on zależny jedynie od zmiennej MOV.

Porównanie wszystkich modeli

W celu weryfikacji dokładności każdego z modeli, sprawdzimy różnicę przewidzianych wygranych z rzeczywistą liczbą wygranych w następnym sezonie. Użyjemy do tego wyników w sezonie następującym po ostatnim z uwzględnionych w modelach.



Rysunek 1 – Histogramy różnic predykcji

Na powyższych histogramach widzimy jak rozkładają się różnice predykcji w porównaniu do danych rzeczywistych.

Za satysfakcjonujące predykcje uznajemy wartości, gdzie różnica między przewidzianą a rzeczywistą wartością różni się maksymalnie o 3, zarówno w przypadku niedoszacowania jak i przeszacowania.

The purpose of this paper will be to present the process of building different regression models using the R language.

In this paper, we will use linear regression, multiple regression and Poisson regression models. Based on the statistics made available by the NBA league from previous seasons, we will use these models to try to estimate the number of wins of each league team in the following seasons.

We will use leaps and MASS libraries and tools to automate variable selection. In addition, we will build Poisson regression models, also using the above libraries.

We will also show how to determine, using statistical methods, which of the built models achieves the highest accuracy.

Możemy teraz scharakteryzować wszystkie modele:

1. Regresja liniowa – w swojej prostocie poprawnie przewiduje wartości,
2. Regresja wieloraka – poprawna predykcja dla dużej liczby przypadków; niektóre predykcje znacznie zawyżone,
3. Model z MASS – dokładny, zbalansowany model, nieliczne predykcje poza satysfakcjonującym przedziałem,
4. Model z leaps – jedyny model ze skłonnością do zaniżania; nieliczne predykcje poza przedziałem
5. Regresja Poissona – zbalansowany, chociaż niedużo perfekcyjnie trafnych predykcji; jedna predykcja znacznie odstająca od wartości rzeczywistej,
6. Regresja Poissona + MASS – zbalansowany, duża dokładność; również odstająca predykcja.

Wnioski

Modelowane wydarzeń sportowych jest trudne, ze względu na wiele różnych czynników, w większości ludzkich. Jesteśmy w stanie jednak uprościć to zagadnienie i z wykorzystaniem stosunkowo prostych metod matematycznych dokonać dokładnej, jak na możliwe warunki, predykcji wielowymiarowego problemu..

Możemy zaobserwować tendencję do zawyżania wyników przez wykonane przez nas modele.

Wady i trudności

Jedną z największych wad jest brak uwzględnienia czynnika ludzkiego w postaci draftu. Po każdym sezonie zasadniczym następuje loteria, drużyny z niższych miejsc otrzymują prawo wyboru nowych zawodników przed pozostałymi.

Nie jesteśmy też w stanie jednoznacznie określić i sklasyfikować najdokładniejszego z sześciu utworzonych modeli, natomiast widzimy że każdy z nich jest w stanie z pewną dozą dokładności modelować problem.

Źródła

<https://www.nba.com/stats/teams>
<https://stats.oarc.ucla.edu/r/dae/poisson-regression/>
https://www.basketball-reference.com/leagues/NBA_2019.html
<https://www.statology.org/stepaic-r/>
<https://www.dataquest.io/blog/tutorial-poisson-regression-in-r/>

Koło Naukowe Matematyków, Katedra Matematyki Stosowanej,
ul. Warszawska 24, 31-155 Kraków
kontakt.sknmpk@gmail.com, dr Marcin Skrzyński
Opieka naukowa: Adrian Kowalski

